

Григорий Кожанов Представляет...



И Вы представьте...

Основные задачи / сложности:

- Обработка текстов с ошибками и на разных языках
- Классификация роликов без ручной разметки данных
- Создание гибкой модели, способной обучаться на текстах и числовых данных
- Создать автоматизированное решение для классификации



Подход и основные этапы работы

Использование ML

- DistilBERT + Dense Layers: для обработки текстовых данных с параллельной обработкой числовых данных через полносвязные слои. Гибридная архитектура: объединение выходов трансформера и Dense слоев для финальной классификации.
- Обучение на снippetах данных и на всем датасете.
- Максимальный F1-score – 0.56
- Ограничения: технические – для загрузки более сложных моделей и более «богатых» параметров нужно более мощное оборудование
- Результат- импортируемый модуль



В поисках киллер-фичи.

- Наставник намекнул, я поверил))
- Были проверены разные условия расщепления
- 34 класса выделяются по минимальному паттерну
- Для остальных классов есть индивидуальные доп. условия.
- Созданы словари для классов и для паттернов (инструкций)
- Создана функция для классификации
- Максимальный F1-score – 0.96
- Ограничения: функциональные- не автоматизировано
- Результат: функция.



План автоматизации:

- каскадная классификации: от однозначно определяемых классов к сложным
- использование классификаторов OVR
- штрафы на длину паттернов
- стоп-паттерны
- именованные сущности



Ошибки разметки

- ЖилаБыла Царевна vs Царевны + есть прямые ошибки (мультик для детей "Пип и Альба)

- Фиксики - Непонятна логика разметки. В класс попадают как песенки с Фикисками, так и не попадают другие экземпляры- такие же песенки.

- Синий Трактор vs ЖилаБыла Царевна – пересечение по песенкам

- Малышарики vs ЖилаБыла Царевна – также

- Приключения Пети и Волка – id 38654- ошибочно размечен, 60320, 74490 – не размечены

- Крутиксы – не ошибки, но непонятна разметка на некоторых рилсах

- Чебурашка - 73732 none [Трогательные моменты дружбы между Чебурашкой и Геной Союзмультфильм shorts]

- Ну_погоди каникулы пересекается с Петей и Волком – непонятные правила

- Цветняшки – не все попадают в разметку. По-моему д.б. больше



Уходим в закат...



Спасибо за внимание!